

# Introducción a estadística. Uso de Tablas

Hugo J. Bello

## Definiciones Básicas

- Una **población** es un conjunto de todos los elementos que estamos estudiando, acerca de los cuales intentamos sacar conclusiones. Debemos definir esa población de modo que quede claro cuándo cierto elemento pertenece o no a la población.
- Una **muestra** es una colección de algunos elementos de la población, no de todos.
- Una **muestra representativa** contiene las características relevantes de la población en las mismas proporciones en que están incluidas en tal población.

### Ejemplo

En las elecciones generales, la **población** sería el conjunto total de votantes. Una muestra sería seleccionar a 1000 individuos para intentar predecir el resultado de las elecciones. La muestra será **representativa** si contiene la misma proporción de mujeres y hombres que la población votante, geográficamente todas las regiones están proporcionalmente representadas...

## Variables estadísticas

La noción de variable estadística, es una simplificación del concepto de *variable aleatoria* que veremos en temas posteriores. De momento, definiremos *variable estadística* como:

característica o cualidad de un individuo que está propensa a adquirir diferentes valores. Estos valores, a su vez, se caracterizan por poder medirse.

### Tipos de variables estadísticas

- **Cuantitativas:** Pueden ser medidas numéricamente.
  - **Continuas:** Puede tomar cualquier valor dentro de un intervalo o intervalos
  - **Discretas:** Solo toma una cantidad discreta de valores (por ejemplo una cantidad finita de valores)
- **Cualitativas:** son aquellas características o cualidades que no pueden ser calculadas con números, sino que son clasificadas con palabras

### Ejemplo

- Cualitativa: Situación laboral de una persona (empleado / estudiante / paro).
- Cuantitativa continua: IPC, IBEX
- Cuantitativa discreta: número de hermanos, edad.

## Las tablas de frecuencias

Pensemos en los siguientes datos: Supongamos que hemos extraído una muestra de la producción diaria de 30 telares de alfombras

16.2, 15.7, 16.4, 15.4, 16.4, 15.8, 16.0, 15.2, 15.7, 16.6, 15.8,  
 16.2, 15.9, 15.9, 15.6, 15.8, 16.1, 15.9, 16.0, 15.6, 16.3, 16.8,  
 15.9, 16.3, 16.9, 15.6, 16.0, 16.8, 16.0, 16.3

Observamos que los datos presentan repeticiones y que por lo tanto podemos hablar de *frecuencias* de ciertos valores de datos como por ejemplo 15.6 aparece tres veces.

lo primero que vamos a hacer es **ordenar los datos** y lo segundo **apuntar cuantas veces aparece cada dato**

valor	nº de veces que aparece
15.2	1
15.4	1
15.6	3
15.7	2
15.8	3
15.9	4
16.0	4
16.1	1
16.2	2
16.3	3
16.4	2
16.6	1
16.8	2
16.9	1

Esto que acabamos de hacer es una **tabla de frecuencias** y es la manera más directa de estudiar los datos, especialmente cuando hay repeticiones.

Por último, la tabla anterior tiene quizás demasiadas columnas, una idea sería *resumir* la información agrupando los datos por intervalos. Por ejemplo podemos tomar intervalos de longitud 0.5 e ir anotando cuantos valores encontramos que pertenezcan a ese intervalo.

intervalo	nº datos en el intervalo
[15, 15.25)	1
[15.25, 15.5)	1
[15.5, 15.75)	5
[15.75, 16)	7
[16, 16.25)	7
[16.25, 16.5)	5
[16.5, 16.75)	1
[16.75, 17)	3

**Definición**

Una **tabla de frecuencias** (también conocida como tabla de relaciones de frecuencias) es una tabla en la que se organizan los datos en clases, es decir, en grupos de valores que escriben una característica de los datos y muestra el número de observaciones del conjunto de datos que caen en cada una de las clases.

**Notación**

Si estamos ante una tabla de frecuencias

- A cada observación (habitualmente de la muestra ordenada) de la muestra la llamaremos  $x_i$
- Al  $n^o$  de veces que aparece el dato  $x_i$  lo llamaremos **frecuencia absoluta** y lo denotaremos por  $n_i$
- Al número total de datos lo llamaremos  $N$
- A la suma de la frecuencia  $n_i$  más todas las anteriores le llamamos **frecuencia absoluta acumulada** y la denotamos por  $N_i$ .

Si la tabla está agrupada por intervalos

- A cada intervalo llamaremos  $I_i = [l_i, l_{i+1})$
- al valor medio del intervalo lo llamaremos **marca de clase**  $x_i = \frac{l_i + l_{i+1}}{2}$
- las frecuencias absoluta y absoluta acumulada se calculan igual pero en vez de contar el número de veces que aparece el dato contamos el *número de datos encontrados en el intervalo*.

Juntemos todo esto en el ejemplo anterior tenemos para la tabla sin agrupar

$x_i$	$n_i$	$N_i$
15.2	1	1
15.4	1	2
15.6	3	5
15.7	2	7
15.8	3	10
15.9	4	14
16.0	4	18
16.1	1	19
16.2	2	21
16.3	3	24
16.4	2	26
16.6	1	27
16.8	2	29
16.9	1	30

Y para la tabla agrupada por intervalos tenemos

intervalo	$x_i$	$n_i$	$N_i$
[15, 15.25)	15.125	1	1
[15.25, 15.5)	15.375	1	2
[15.5, 15.75)	15.625	5	7
[15.75, 16)	15.875	7	14
[16, 16.25)	16.125	7	21
[16.25, 16.5)	16.375	5	26
[16.5, 16.75)	16.625	1	27
[16.75, 17)	16.875	3	30

## Medidas de concentración

Las medidas de concentración proporcionan información de los *valores centrales* en torno a los cuales se distribuyen los datos.

Son cálculos que realizaremos usando distintas estrategias sobre las tablas de frecuencias que hemos visto

### Media

En general la media aritmética de un conjunto de números

$$x_1, x_2, x_3, \dots, x_n$$

se obtiene sumando todos valores y dividiendo por el número de sumando es decir

$$\frac{x_1 + x_2 + x_3 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

a este valor se le denota  $\bar{x}$

### Idea geométrica

Dados dos puntos en el espacio  $x$  e  $y$ , el punto medio entre ambos es justamente  $(x + y)/2$ . Esto ocurre tanto en la recta como en el espacio




Figure 1: punto medio

### Cómo calcularla

Para calcularlo, si tenemos una tabla de frecuencias

$x_i$	$n_i$
$x_1$	$n_1$
$x_2$	$n_2$
$x_3$	$n_3$
$\vdots$	$\vdots$
$x_N$	$n_N$

puesto que cada valor  $x_i$  se repite  $n_i$  veces, calcularemos la media de la siguiente manera

$$\bar{x} = \frac{x_1 \cdot n_1 + x_2 \cdot n_2 + x_3 \cdot n_3 + \dots + x_N \cdot n_N}{N} = \frac{1}{N} \sum_{i=1}^N x_i \cdot n_i$$

en el caso de que tengamos una tabla de frecuencias agrupadas por intervalos

$I_i$	$x_i = \frac{x_i + x_{i+1}}{2}$	$n_i$
$[l_1, l_2)$	$x_1$	$n_1$
$[l_2, l_3)$	$x_2$	$n_2$
$[l_3, l_4)$	$x_3$	$n_3$
$\vdots$	$\vdots$	$\vdots$
$[l_K, l_{K+1})$	$x_K$	$n_K$

haremos lo mismo pero usando la marca de clase  $x_i = \frac{l_i + l_{i+1}}{2}$

### Ejemplos

La siguiente tabla recoge las ventas de 100 sucursales de una empresa

ventas (miles)	$x_i$	$n_i$	$x_i \cdot n_i$
[700, 800)	750	4	3000
[800, 900)	850	7	5950
[900, 1000)	950	8	7600
[1000, 1100)	1050	10	10500
[1100, 1200)	1150	12	13800
[1200, 1300)	1250	17	21250
[1300, 1400)	1350	13	17550
[1400, 1500)	1450	10	14500
[1500, 1600)	1550	9	13950
[1600, 1700)	1650	7	11550
[1700, 1800)	1750	2	3500
[1800, 1900)	1850	1	1850

calculemos la media

$$\begin{aligned}
 \bar{x} &= \frac{1}{N} \sum_{i=1}^N x_i \cdot n_i \\
 &= \frac{750 \cdot 4 + 850 \cdot 7 + 950 \cdot 8 + \dots + 1850 \cdot 1}{100} \\
 &= \frac{3000 + 5950 + 7600 + 10500 + 13800 + 21250 + 17550 + 14500 + 13950 + 11550 + 3500 + 1850}{100} \\
 &= \frac{125000}{100} = 1250
 \end{aligned}$$

### Moda

La **moda** (*Mo*) es el valor que aparece con mayor frecuencia en un conjunto de datos. Si hubiera varios datos con frecuencia máxima (no hay un único dato con mayor frecuencia sino varios) la moda serían todos ellos. Por lo tanto la moda puede no ser única.

**Cómo calcularla**

Simplemente buscamos el valor o valores con mayor frecuencia absoluta.

**Ejemplo**

La siguiente muestra es el resultado realizar una muestra de renta per capita en un barrio concreto de madrid (en miles de euros anuales brutos)

14, 23, 15, 17, 12, 0.5, 30, 12, 23, 18, 25, 30, 15, 12, 23

$x_i$	$n_i$
0.5	1
12	3
14	1
17	1
18	1
23	3
30	2

Luego la moda es:

$$Mo = 12, 23$$

**Mediana**

La mediana  $Me$  representa el valor de la variable de posición central en un conjunto de datos ordenados.

Si tenemos un número impar de datos, tomamos como mediana simplemente el valor que ocupe la posición central al ordenarlos, por ejemplo para los datos

1, 2, 3, 4, 5

El dato central es 3 así que  $Me = 3$ .

Si tenemos un número par de datos, al ordenar los datos no encontraremos un dato central, sino dos, con lo cual tomaremos como mediana la media entre estos dos datos centrales. Por ejemplo para los datos

7, 8, 9, 10, 11, 12

No hay un dato central, podríamos decir que los valores 9 y 10 son *centrales* así que tomamos  $Me = (9 + 10)/2$

**Cómo calcularla**

Si los datos no están en una tabla de frecuencias, haremos lo que hemos comentado en los párrafos anteriores. Si hemos organizado los datos por frecuencias, haremos lo siguiente:

Dada una tabla (en la que calculamos también las frecuencias acumuladas)

$x_i$	$n_i$	$N_i$
$x_1$	$n_1$	$N_1$
$x_2$	$n_2$	$N_2$
$x_3$	$n_3$	$N_3$
$\vdots$	$\vdots$	$\vdots$
$x_N$	$n_N$	$N_N$

1. Buscamos el valor que ocupa la *posición central* mirando en la tabla cual es el primer dato  $x_i$  cuya frecuencia acumulada supera o iguala  $N/2$ .
2. Si encontramos un dato cuya frecuencia acumulada  $N_i$  **igual**a  $N/2$  tomamos como mediana la media de ese dato  $x_i$  y el siguiente  $x_{i+1}$ .  $Me = \frac{x_i + x_{i+1}}{2}$ .
3. Si no encontramos uno cuya  $N_i$  iguale a  $N/2$  sino uno que la supere directamente, tomamos ese dato como mediana.  $Me = x_i$ .

### Ejemplo 1

Se recogen datos de la satisfacción de 37 usuarios con un servicio. Los usuarios responden con notas del 1 al 9.

nota	$n_i$	$N_i$
1	2	2
2	2	4
3	4	8
4	5	13
5	8	21
6	9	30
7	3	33
8	4	37
9	2	39

Calculamos  $N/2$  y obtenemos  $39/2 = 19.5$ . Encontramos que el la primera frecuencia acumulada que supera o iguala 19.5 es 21, no habiendo ninguna que la iguale, de modo que  $Me = 5$

### Ejemplo 2

Si en el ejemplo anterior en lugar de la tabla anterior hubieramos tenido la tabla:

nota	$n_i$	$N_i$
1	2	2
2	2	4
3	4	8
4	5	13
5	8	21
6	9	30
7	3	33
8	4	37
9	5	42

En este caso  $N/2 = 21$  y al mirar entre las frecuencias acumuladas vemos que hay una que iguala 21, luego la mediana será

$$Me = (5 + 6)/2 = 5.5$$

## Bibliografía

- John A. Rice. Mathematical Statistics and Data Analysis
- F. M. Dekking, C. Kraaikamp, H. P. Lopuhaa, L. E. Meester. A Modern Introduction to Probability and Statistics. Understanding Why and How.
- [https://es.wikipedia.org/wiki/Distribuci%C3%B3n\\_Bernoulli](https://es.wikipedia.org/wiki/Distribuci%C3%B3n_Bernoulli)
- [https://es.wikipedia.org/wiki/Distribuci%C3%B3n\\_binomial](https://es.wikipedia.org/wiki/Distribuci%C3%B3n_binomial)
- [https://es.wikipedia.org/wiki/Distribuci%C3%B3n\\_geom%C3%A9trica](https://es.wikipedia.org/wiki/Distribuci%C3%B3n_geom%C3%A9trica)